

## Introdução à análise de dados com Python

Olá!

Você já ouviu falar de Python?

Python é uma das linguagens mais utilizadas para a construção de sistemas, aplicações e principalmente, análise de dados e Machine Learning que será o conteúdo da nossa aula de hoje. Nós iremos abordar, de maneira introdutória a análise de dados utilizando a linguagem Python.

Existem várias outras linguagens que nos permitem executar análises sobre os dados, porém, Python, por sua facilidade de aprendizado a sua curva de aprendizado suave popularizou o uso de Python para esse fim, uma vez que não somente programadores ou desenvolvedores da área de tecnologia da informação trabalham com análise de dados.

Nesta aula, nós iremos aprender a utilizar os comandos básicos da biblioteca Pandas, que servirá tanto para a leitura de dados quanto para a execução de algumas análises de uma maneira semiautomática, podemos dizer assim.

Com poucos comandos, podemos fazer grandes coisas. Também iremos ver outras bibliotecas no decorrer da aula que nos auxiliarão na análise, como na construção de gráficos construção de tabelas ou na seleção de dados específicos.

Então, em nossa primeira célula do Jupyter Notebook que utilizaremos ao longo desta aula para aplicar nossos códigos em Python iremos colocar o seguinte texto:

```
import pandas as pd
```

O que essa linha está dizendo? O "import" irá indicar para o Python que nós iremos importar uma biblioteca. "Pandas" é a biblioteca que nós iremos utilizar, "as" seria uma palavra reservada da linguagem Python para dar um apelido para a biblioteca que iremos utilizar, no caso, "pd". Dessa maneira, nossa linha completa será.

Ao executar esta primeira linha, não iremos ter nenhum resultado, mas uma numeração irá surgir ao lado da célula, que irá indicar que esta célula foi executada. Com isso, nós já indicamos ao Python que iremos utilizar a biblioteca Pandas. Dessa maneira, o Pandas pode ser utilizado para efetuar a leitura de um conjunto de dados.

Juntamente com esta aula, temos um conjunto de dados de frutas que exibe algumas características sobre elas que podemos utilizar para aprender a analisar dados. Na próxima célula, na próxima linha, iremos escrever um comando para efetuar uma leitura deste conjunto de dados. Então, nesta linha, iremos escrever: "frutas", que será uma variável que armazenará o conjunto de dados que iremos ler; "= pd", que seria a abreviação do nosso Pandas, ou o apelido que demos ao Pandas na célula anterior. ".read\_table(", que seria o método do Pandas para efetuar a leitura de um arquivo, "read\_table": "read", de ler; "table",

## Tipo do documento

de tabela: "ler uma tabela". E iremos passar, como parâmetro desta função: "fruit\_data\_with\_colors", com cada palavra separada por um underline, ou underscore ".txt".

Dessa maneira, nós estamos indicando a função do "read\_table" que iremos ler o arquivo "fruit\_data\_with\_colors.txt". Além disso, iremos passar, também, como segundo parâmetro, o separador iremos colocar uma vírgula, após o nome do arquivo e utilizar a palavra "sep", com "s".

Por que utilizamos isso?

O nosso conjunto de dados está sendo separado por tabulações. A indicação de uma linha para outra, ou de uma coluna para outra é feita por tabulações. Então, abrindo o arquivo de frutas, podemos notar que ele possui várias colunas, o rótulo e nome das frutas, o subtipo de cada uma e a massa, com largura altura e cor de cada fruta e cada linha do nosso arquivo vai ter uma fruta diferente.

Logo, neste conjunto de dados para separar o label, ou rótulo de uma fruta, do seu nome temos uma tabulação na mesma linha, que irá indicar ao nosso Pandas que se trata de colunas ou atributos diferentes do nosso conjunto de dados.

Logo, a nossa linha ficou:

- "frutas", que é a variável que receberá nosso conjunto de dados
- "= pd", representando o Pandas
- ".read\_table", que seria a função para a leitura de uma tabela
- "('fruit", de fruta
- "\_data", de dados;
- "\_with", de com
- "\_colors", de cores;
- ".txt"
- "(['fruit\_data\_with\_colors.txt',sep='\t'])".

Esta linha irá carregar o nosso conjunto de dados. Utilizando Shift + Enter, iremos executar esta célula na qual a linha está contida. Dessa maneira, o Python foi capaz de ler o conjunto de dados. O número ao lado da célula onde a linha foi executada indica que não houve nenhum erro nesta leitura.

Na próxima linha, podemos simplesmente escrever "frutas", que é a variável que armazena nosso conjunto de dados e executá-la somente com o "frutas". Vamos executar a célula com uma única linha, com "frutas". Ao executarmos esta linha, Shift + Enter iremos

## Tipo do documento

conseguir encontrar uma tabela com os dados que estão armazenados no nosso conjunto de dados sendo apresentados nesta tabela. Esta tabela é dividida em linhas e colunas.

Cada coluna representa um atributo de uma fruta no caso do "fruit\_data\_with\_colors" que é o conjunto de dados que estamos utilizando e é de frutas nós iremos ter informações sobre frutas. Então, nós temos sete colunas para o nosso exemplo: "fruit\_label", "fruit\_name", "fruit\_subtype", "mass", "width", "height" e "color\_score" que são atributos diferentes da nossa fruta. E cada linha se refere a uma fruta diferente.

Dessa maneira, nós utilizamos o Pandas para abrir o conjunto de frutas que iremos utilizar nesta aula. Na célula seguinte, podemos efetuar uma leitura do nosso conjunto de dados. Na realidade, nosso conjunto de dados já foi lido, mas não temos uma noção, uma vez que são muitos dados de quantas frutas nós temos, nem de quantas colunas.

No caso deste exemplo, é fácil contar porque são apenas sete colunas, mas em problemas reais de aprendizado de máquina ou de ciência de dados, podemos ter muitas colunas a mais. Uma maneira simples de verificar a quantidade de linhas e colunas do nosso conjunto de dados, vai ser descrita na próxima célula onde iremos colocar a seguinte linha: "frutas.shape"

Ao executar esta célula, iremos ter o número de linhas que é "59", para este exemplo, e o número de colunas, que é "7". Então, o resultado desta célula será: "(" e um primeiro número, que será o número de linhas no nosso caso, "59" ", " e o número de colunas, que no nosso caso, será "7" e por fim, ")", indicando que é uma tupla do Python.

Nós conseguimos, até agora, ler o nosso conjunto de dados representá-lo em uma tabela e verificar o tamanho do mesmo. A próxima função que podemos verificar é exibir apenas as primeiras linhas do nosso conjunto de dados.

Iremos escrever na próxima célula: "frutas", que é o nosso conjunto de dados a variável onde está armazenado o nosso conjunto de dados ".head", de cabeçae iremos passar, entre parênteses, após o "head", um valor que será equivalente ao número de linhas exibidas. Iremos colocar "5", que é equivalente a cinco linhas as cinco primeiras linhas do conjunto de dados.

A nossa linha ficou: "frutas.head(5)". Dessa maneira, ao executar a linha, será exibida uma tabela com as cinco primeiras linhas do nosso conjunto de dados. Com isso, encerramos o primeiro vídeo desta aula apresentando como efetuar uma leitura de um conjunto de dados como extrair informações sobre a quantidade de linhas ou quantidade de elementos do nosso conjunto de dados e o número de colunas do nosso conjunto de dados e apresentamos,

## Tipo do documento

também, uma função para apresentar os primeiros elementos e linhas do nosso conjunto de dados.

Até a próxima!