

Análise estatística de um conjunto de dados

Olá! Neste vídeo, iremos aprender como executar uma análise estatística sobre um conjunto de dados. Iremos utilizar o conjunto de dados de frutas presumindo que ele já foi lido em um passo anterior utilizando a biblioteca Pandas. Logo, iremos utilizar a variável "frutas". Podemos colocar em uma célula vazia a palavra "frutas" que se refere à variável onde armazenamos o conjunto de dados lido pela biblioteca Pandas e iremos ter uma tabela ao executar este comando. Uma vez que estamos com a variável que possui os dados lidos, no caso, a variável "frutas" e temos a tabela em mãos podemos utilizar o seguinte comando: `frutas.describe()`

Então, nossa linha será: "frutas.describe", de descrever, "()".

Ao executar esta linha, iremos ter uma tabela um pouco diferente da que tínhamos antes. Essa tabela irá apresentar um subconjunto das colunas que tínhamos antes e cada linha representará algo estatístico do conjunto de dados. Primeiramente, vale ressaltar que as únicas colunas que serão apresentadas no "describe" serão as colunas que se referem a valores numéricos. O "describe" irá efetuar análises estatísticas então, iremos obter apenas as colunas numéricas que, no caso, seria a coluna "fruit_label" uma coluna do dado original que possui um número que é um número relativo ao nome da fruta. Para o conjunto de dados, nós temos que toda fruta cujo "fruit_name" seja "apple", ou maçã, o seu label correspondente será igual a "1" e toda fruta que for "mandarin", ou tangerina, terá "fruit_label" igual a "2".

Temos, também, as frutas laranja, "orange", que terá um "fruit_label" igual a "3" e um limão, ou "lemon", em inglês que será a nossa fruta cujo "fruit_label" é "4".

Então, embora tenhamos a coluna "fruit_label", que é um número esses números não representam uma ideia de quantidade, eles representam, apenas, uma classificação; uma vez que, se o número "1" representa uma maçã, e o número "2" é uma tangerina, a soma desses números, que é igual a 3, não irá significar uma laranja. Então, esses números não servem para ser somados ou subtraídos. Não existe uma semântica para seus significados nem um significado para a subtração ou adição desses números. Ainda que esta coluna apareça ao executarmos o "describe", ela não tem muito significado estatístico.

Tipo do documento

As demais colunas são a massa, ou "mass", em inglês "width", que seria o comprimento da nossa fruta a altura, ou "height", como está no conjunto de dados e a "color_score" que seria um valor referente à cor da nossa fruta que é um valor que vai variar entre 0 e 1 indicando a intensidade da cor.

Esses atributos são números, uma vez que podemos fazer comparações por exemplo: uma massa de 60 é maior que uma massa de 59 logo, podemos fazer comparações enquanto que, no "fruit_label", a tangerina, ou "mandarin" cujo "fruit_label" é "2" não é maior que a maçã, cujo "fruit_label" é "1" são apenas rótulos. Mas, na massa, largura, ou comprimento, altura e cor, esses números fazem sentido, eles possuem uma ordenação. Então, falando um pouco de cada uma das linhas iremos ter as seguintes informações: a primeira linha do "describe" é uma contagem, ou "count" que seria o número de elementos que temos no conjunto de dados.

Ele vai ser o mesmo para cada uma das colunas uma vez que temos 59 elementos e cada um deles possui informação em suas colunas logo, o "count" é 59 para cada uma das colunas. Em seguida, na segunda linha, temos "mean", que significa a média que seria a média dos valores encontrados no conjunto de dados para cada uma das colunas "width", que seria comprimento, temos a média para o comprimento no caso do conjunto de dados, temos que a média do seu comprimento é "7,105085" e temos a média para cada uma das colunas. A próxima linha é o desvio padrão que está representado pelas letras "std" ou standard deviation, em inglês. O desvio padrão é uma medida estatística que mensura, em média o quanto os dados se afastam da média.

Esse valor é útil e, em futuras aulas, iremos utilizá-lo para trabalhar melhor com os dados. Em seguida, temos a linha mínimo, ou "Min". Esta linha representa o menor valor encontrado na coluna. Na coluna de massa, a fruta que tem a menor massa no conjunto de dados é igual a "76". As três próximas linhas representam os quartis do conjunto de dados que têm um significado bem simples. Por exemplo, a primeira dessas três linhas se chama "25%". Este "25%" tem como objetivo dizer o seguinte: 25% dos dados do conjunto de dados possuem valores menores do que o valor representado.

No caso, para o conjunto de dados o 25% da massa é "140.0". Isso significa que 25% das frutas do conjunto de dados possui massa menor que "140.0". A próxima

Tipo do documento

linha é "50%" e ela tem um significado parecido, que seria: 50% das frutas têm um valor menor do que o apresentado para dar uma das colunas. A próxima linha também continua com uma ideia parecida, que seria: 75% das frutas possuem uma massa menor que "177.0" no conjunto de dados. Então, são três linhas: "25%", "50%" e "75%" que exprimem a quantidade de frutas, no caso ou de elementos que têm o valor menor que o indicado para suas colunas. Por fim, temos mais uma linha, que é a linha do máximo, ou "max" que reflete o valor máximo encontrado para cada uma das colunas. No caso da coluna de cor, "color_score" teremos que o máximo encontrado foi "0.93". Lembrando que o "cloro_score" indica um valor entre 0 e 1, que indica a intensidade da cor não exatamente qual é a cor em si que está sendo apresentada. Dessa maneira, conseguimos efetuar uma análise estatística básica, mas que já pode responder algumas perguntas.

Podemos descobrir que metade das frutas possuem massa menor que 158.0 ou que 75% das frutas possuem uma cor menor que 0.81. Já seria uma primeira análise feita sobre o conjunto de dados. Na linha seguinte, iremos capturar a descrição para apenas uma das colunas. Vamos supor que só estamos interessados em capturar a descrição para a coluna de massa. Dessa maneira, iremos escrever na nossa linha a seguinte frase: "frutas", que seria a variável que representa o conjunto de dados com o qual estamos trabalhando ".describe()" assim, teremos a descrição do conjunto de frutas. Mas, queremos pegar apenas a coluna de massa então: "[" podemos abrir aspas, simples (') ou duplas (") aqui, iremos utilizar simples e escrever "mass": "mass", que é a maneira como a coluna que representa a massa dos dados está sendo representada "]" A linha, por completo, será descrita como: `frutas.describe()["mass"]`

Ao executarmos esta linha, iremos obter as mesmas estatísticas apresentadas na linha anterior, porém, se referindo apenas às massas das frutas do conjunto de dados. Se quisermos ser mais eficientes na análise ou quisermos ter um dado ainda mais detalhado, podemos repetir a linha anterior: `frutas.describe()["mass"]["min"]`

Dessa maneira, nós teremos a descrição, mas ela vai ser restrita apenas ao valor mínimo da massa da coluna de massa dos dados. Ou seja, executando esta linha: `frutas.describe()["mass"]["min"]`, teremos apenas o valor da fruta que possui a menor

Tipo do documento

massa do conjunto de dados. E, no conjunto de dados, esse número é igual a "76.0". Dessa maneira, estamos conseguindo efetuar uma análise sobre o conjunto de dados. Algo simples que podemos verificar, também é que não precisamos ler todo o conjunto de colunas ao mesmo tempo. Podemos escolher apenas algumas colunas para serem representadas na nossa tabela. Então, na próxima linha, executaremos a seguinte instrução: `frutas["mass"]`.

Dessa maneira, executando esta linha teremos, apenas, a sequência das massas das frutas representadas no conjunto de dados. Além disso, podemos, também, pegar mais de uma coluna então, podemos utilizar, na próxima linha: `frutas[[` iremos passar uma lista de colunas dentro dos colchetes para `frutas[[` então, podemos colocar duas colunas "mass" e "color_score", por exemplo e, executando esta linha, iremos ter os valores para essas duas colunas. A nossa linha ficou da seguinte maneira: `frutas[["mass","color_score"]]`. Dessa maneira, nós temos "frutas" e, entre colchetes, passamos uma lista com o conjunto de colunas que gostaríamos de exibir. Então, executando esta linha, nós iremos ter apenas as colunas especificadas do conjunto de dados. No caso, utilizamos "mass" e "color_score" ou a massa e intensidade de cor da fruta. Outras análises que podemos fazer é ao invés de escolher só um conjunto específico de colunas podemos pegar só um conjunto específico de linhas. Como podemos fazer isso? Utilizando a variável "frutas", em uma linha, dentro de uma célula: `frutas[` podemos passar a nossa linha inicial, aqui, iremos utilizar "10" ":", a nossa linha final, que seria "15"]. Então, a nossa linha ficou: `frutas[10:15]`.

O que esta linha irá retornar para nós?

Esta linha, ao ser executada irá retornar da linha 10 até a linha 14, ou seja, do intervalo fechado do primeiro número até o intervalo aberto do segundo número. Assim, o segundo número não é contemplado. Dessa maneira, nós estamos apresentando só um conjunto específico de linhas do conjunto de dados: as linhas 10, 11, 12, 13 e 14. Mesmo que tenhamos colocado `frutas[10:15]` o "15" não vai ser representado. Por que o "15" normalmente não é apresentado? Vamos supor o seguinte, vamos definir uma variável: `i = 15` em uma célula, e vamos rodar esta célula. E iremos utilizar variáveis para expor o conjunto de linhas que vai ser apresentado.

Tipo do documento

Então, podemos colocar na próxima linha: `frutas[i - 5:i]`. "i" é a variável que acabamos de definir, que seria "i = 15", mas aqui, iremos colocar apenas "i", ou seja, 15 - 5, que é igual a 10. Então, nós queremos verificar as linhas de "i - 5" até "i" ou seja, de "10" até "15". Ao executar este comando: `frutas[i-5:i]`, iremos ter o conjunto de dados apresentado. Esse conjunto de dados se refere, nos dados, às maçãs, às cinco maçãs.

E na próxima linha, no próximo comando iremos utilizar algo bem parecido: `"fruits"`, ou `frutas[i:i+5]`, ou seja, iremos verificar, agora da linha "i" até a linha "i + 5" que seria do "15" ao "20" e o resultado serão as linhas "15", "16", "17", "18" e "19". Dessa maneira, mesmo que estejamos utilizando o "i" na primeira célula estamos utilizando do "i - 5" até o "i" foram apresentados do "10" ao "14". Na próxima linha, do "i" ao "i + 5", foram do "15" ao "19". Dessa maneira, não tivemos nenhuma linha repetida porque o intervalo é aberto no final e fechado no início. O número 15 inclui um número no início e exclui um número do final.

Isso também pode ser combinado para exibir um conjunto de colunas e um conjunto de linhas, ou seja, podemos apresentar algumas colunas específicas de um certo conjunto de linhas. Por exemplo, podemos colocar "frutas" em uma linha nova em uma nova célula: `frutas[["mass", "color_score"]]`.

Dessa maneira, iremos apresentar apenas as massas as colunas de massa e de cor.

Em seguida: `[i:i+5]` que é igual a 15, como definimos anteriormente.

Dessa maneira, iremos apresentar a colunas de massa e cor para as linhas "15" até "19". Esta é a execução da nossa linha: `frutas[["mass", "color_score"]][i:i+5]`.

Assim, conseguimos efetuar algumas análises sobre pedaços do conjunto de dados. Neste vídeo, você estudou como efetuar análises estatísticas tais como: média, desvio padrão, mínimo e massa sobre o conjunto de dados e estudou como selecionar apenas uma parte do conjunto de dados de frutas que é o exemplo que viemos utilizando até agora. Esses resultados também podem ser combinados você pode efetuar a descrição de apenas um pedaço do conjunto de dados utilizando o `".describe"` no final da linha. Este também é um método para executar análises

Tipo do documento

estatísticas em apenas algumas colunas ou algumas linhas. Com isso, encerramos este vídeo.

Até a próxima!