

Análise e visualização de um conjunto de dados

Neste vídeo, iremos aprender a apresentar os dados utilizando gráficos. Então, para utilizar estes gráficos iremos utilizar outra biblioteca do Python que é a biblioteca Matplotlib. Para utilizá-la, podemos aplicar o seguinte comando em uma célula até então vazia: `import matplotlib.pyplot as plt`

E o que isso significa esse comando?

Estamos importando o módulo "pyplot" da biblioteca Matplotlib e estamos dando o apelido, ou chamando essa importação de "plt" que fica bem mais fácil do que escrever todo esse comando todas as vezes que precisássemos usá-lo. Então, executando esta linha, nós iremos importar essa biblioteca esse módulo "pyplot" da biblioteca Matplotlib. A primeira coisa que tentaremos fazer é verificar o balanceamento dos dados. Por que precisamos fazer este balanceamento? Quando trabalhamos com aprendizado de máquina ou ciência de dados, é interessante saber se o conjunto de dados é balanceado, ou seja, se as categorias, no caso, os tipos de frutas, são balanceados.

Isso tem importância nos algoritmos de aprendizado de máquina que iremos conferir mais adiante. Então, iremos usar o seguinte comando para iniciar a análise: iremos criar uma variável, chamada "freq" que é igual ao conjunto de dados até então, estamos utilizando a variável "frutas" para armazenar. Vamos pegar a coluna "fruit_name" e utilizar uma função chamada "value_counts" que vai efetuar uma contagem das frutas pelos seus nomes. Então, a linha ficou com: `freq. = frutas['fruit_name'].value_counts()`. "frutas" é a variável onde os dados estão armazenados.

Esta função, "value_counts", permite que se faça uma leitura e uma contagem dos dados, de acordo com os seus nomes que estão na coluna "fruit_name" e essa informação será armazenada na variável "freq". Então, a execução desta linha não irá dar sinal algum visível de execução. Mas, na célula seguinte, após executarmos a célula anterior se colocarmos apenas o "freq" e executarmos iremos ter uma coluna com o nome de cada fruta e o número de vezes que ela apareceu no conjunto de dados. No caso, "apple", ou maçã, apareceu 19 vezes "orange", ou laranja, apareceu 19 vezes "lemon", ou limão, apareceu 16 e "mandarin", que é tangerina, apareceu

cinco vezes. E com esse conjunto de dados, nós podemos gerar um gráfico que pode facilitar a análise desse conjunto de dados. Para criar esse gráfico, na célula seguinte podemos executar os seguintes comandos: `freq..plot(kind="bar")`.

Esta linha irá indicar o seguinte: eu estou usando a coluna de contagem das frutas, que é o "freq" ".plot", que é a função para criar um gráfico e como parâmetro desta função, dentro dos seus parênteses estamos passando o parâmetro "kind", que é o tipo de gráfico apresentado "'bar'" que é o gráfico de barras. Encerramos com um parêntese fechando a linha. Esta linha vai gerar um gráfico de barras só que ela não vai apresentar este gráfico de imediato. Então, iremos quebrar a linha, apertando o Enter e dentro da mesma célula, colocaremos uma segunda linha de comandos: `plt.show()`. "plt" é do "matplotlib.pyplot" representando a biblioteca Matplotlib e seu módulo "pyplot" uma função sem parâmetro.

Ao executar esta célula, com essas duas linhas iremos ter um gráfico de barras indicando as quantidades de cada uma das frutas. Além desta, podemos verificar, também, a mesma análise dentro de algumas colunas mais específicas. Podemos trabalhar com algum conjunto específico de frutas, apenas. Por exemplo, na próxima linha, iremos verificar quais frutas são maçãs. Então, vamos utilizar o seguinte: "frutas", a variável que representa o conjunto de dados "[fruit_name]", ou seja, estamos utilizando apenas a coluna "fruit_name" do conjunto de dados de frutas "==" retrata que não estamos fazendo uma atribuição de variáveis mas sim, uma comparação, e depois disso, daremos mais um espaço, e "'apple'" ou maçã.

Esta linha irá verificar no conjunto de dados quais são as frutas que têm o valor "apple" na coluna "fruit_name", ou seja, quais frutas são maçãs. Então, a linha é: `frutas["fruit_name"] == "apple"`.

Ao executar esta linha, este comando iremos ter o resultado de várias linhas com as palavras "True" ou "False". "True" significa as linhas cuja coluna "fruit_name" tem como resultado "apple", ou maçã e "False" é o caso contrário, quando o resultado o que existe dentro de "fruit_name", não é "apple". Temos vários "Trues" e "Falses". Iremos armazenar esta linha em uma variável chamada "maçãs". Como no Python e no Jupyter nós evitamos utilizar variáveis com caracteres especiais, armazenaremos uma variável "macas" que seria "maçãs" sem os caracteres especiais como o cedilha

(ç) ou o símbolo do til (~). Então, teremos: "macas = " e o mesmo comando da linha anterior: `frutas["fruit_name"] == "apple"`.

Executando esta linha, iremos ter que a variável maçãs, ou "macas", como está grafado terá a informação de quais linhas são referentes a maçãs e quais não são. A seguir, na linha seguinte, na célula seguinte podemos apresentar a tabela contendo apenas maçãs e podemos fazer isso facilmente utilizando a variável "frutas" "[" e iremos passar a variável construída na linha anterior: `macas]` e podemos executar a linha. Assim, teremos uma análise gráfica, um gráfico com a tabela representando apenas as frutas cujo nome é maçã. Dessa maneira, podemos apresentar o conjunto de dados de acordo com uma variável em específico. Podemos, também, verificar algo parecido para um número utilizando, na próxima linha, a variável "frutas" "["`mass`", para pegar a massa a coluna de massa das frutas "]" e podemos utilizar o símbolo de maior que (`>`) e o valor "175" após isso. Ao executar esta linha: `frutas["mass"]>175` iremos ter uma situação similar à anterior onde o resultado desta execução será o número de linhas onde a massa da fruta é maior que 175. Na linha seguinte, podemos executar uma consulta à análise gráfica das frutas, que são maçãs e que são pesadas de uma maneira bem simples.

Podemos colocar na linha: `frutas[" macas " & frutas["mass"] > 175]`, e a variável "pesadas" que podemos definir da seguinte maneira: "pesadas" são as frutas: `frutas[" cujas massas: "mass"]` são maiores que 175.

Dessa maneira, ao executarmos esta linha: `frutas[macas & frutas["mass"] > 175]`, iremos notar as maçãs cujas massas são maiores que 175. Aqui, neste caso, não conseguimos verificar nenhuma. Então, podemos criar uma variável, chamada "pesadas" que seria igual às frutas cujas massas são maiores que 175. Executando novamente a linha anterior: `frutas[macas & pesadas]`, teremos as frutas que são maçãs e que são pesadas. Utilizamos esta abordagem para mostrar que não adianta simplesmente colocar a condição entre colchetes para o conjunto de frutas. Neste caso, estamos utilizando a definição de frutas pesadas que executamos na linha anterior nos aproveitando, também, das maçãs, também definidas anteriormente. Então, a linha foi: `frutas[macas & pesadas]` sendo que "pesadas" foi definido na linha

anterior, sendo: `pesadas = frutas["mass"] > 175`. Uma vez definido como algo pesado, podemos fazer a consulta com: `frutas[macas & pesadas]`.

Dessa maneira, temos as frutas que são maçãs e que são pesadas sendo "pesadas" coisas acima de 175 de massa. Teremos, no conjunto de dados, só quatro maçãs com essa propriedade. Podemos continuar a análise gráfica nos aprofundando na análise dentro das colunas e aplicando condições. Como podemos fazer isso?

Na próxima célula, iremos utilizar duas linhas: onde a primeira linha: `"X1"` é igual a `"frutas"`, que são `"macas"` e são `"pesadas"` da mesma forma que fizemos na linha anterior `"["` novamente, e iremos colocar o comprimento entre aspas simples: `"width"]`. Ou seja, até agora, temos na linha: `X1 = frutas[macas & pesadas]["width"]`. `"macas"` é a variável que representa as linhas cujas frutas são maçãs; `"& pesadas"` são as frutas cujas massas são maiores que 175.

Dentro da mesma célula, podemos quebrar linha e, na linha de baixo, iremos colocar o que foi descrito na de cima, fazendo apenas algumas mudanças: onde havia `"X1"`, iremos mudar para `"X2"`, e onde havia `"width"`, que seria o comprimento, iremos substituir por `"height"`, que seria a altura.

Dessa maneira, nós temos duas linhas onde a primeira está pegando só as frutas que são maçãs e pesadas e pegando apenas o comprimento delas e na segunda linha, estamos pegando as mesmas frutas, maçãs e pesadas mas, estamos pegando apenas as alturas dessas frutas. Ao executar esta linha, iremos guardar essas informações nas variáveis `"X1"` e `"X2"`, respectivamente. Iremos utilizar, na célula seguinte: `"plt"`, que é a biblioteca do `"pyplotlib"`, `".scatter"` que é o gráfico de dispersão, `"(X1,X2)"`, onde quebraremos a linha, e utilizaremos: `plt.show` para apresentar o gráfico. Executando esta célula, iremos ter um gráfico onde o eixo horizontal representa a largura das maçãs, que são maçãs e pesadas ou seja, maçãs pesadas e o eixo vertical representa a altura dessas maçãs pesadas. Esse gráfico foi gerado, mas não tem muita informação. Então, podemos acrescentar, antes do `"plt.show"` repetindo a célula anterior, podendo copiar e colar a mesma e entre as duas linhas, podemos colocar os rótulos que irão aparecer no gráfico. Então, continuaremos em uma célula seguinte com: `plt.scatter(X1,X2)`.

Na próxima linha, colocaremos: `plt.xlabel("comprimento")`, então podemos quebrar a linha novamente e utilizar: `plt.ylabel("altura")`, depois desta linha: `plt.show()`.

Dessa maneira, nós temos quatro linhas dentro de uma célula e executando estas linhas, esta célula teremos o gráfico da célula anterior, porém, com as legendas dos eixos. onde, no eixo horizontal, teremos o comprimento e, no eixo vertical, teremos a altura. Assim, estamos vendo como construir gráficos a partir de conjuntos de dados. Aqui, utilizamos os dados específicos de maçãs pesadas, mas, retirando esta condição e usando diretamente a variável de frutas, teríamos a informação sobre todos os conjuntos de frutas. Podemos refazer este gráfico reaproveitando a linha onde "X1" e "X2" foram definidos e apagando a parte de "macas" e "pesadas" que está dentro de um dos colchetes nas duas linhas. Então, a primeira linha seria: `X1 = frutas["width"]` e na próxima linha: `X2 = frutas["height"]`.

Estamos redefinindo o "X1" e o "X2" e podemos copiar a célula onde o gráfico é apresentado e executar na linha seguinte esta célula. Então, teremos um gráfico, uma vez que, agora, "X1" e "X2" não estão se concentrando nas frutas que são maçãs e pesadas estamos nos concentrando em todas as frutas e iremos ter um gráfico com todas as informações de comprimento e altura das frutas do conjunto de dados. Além disso, podemos colorir as frutas de acordo com seus rótulos, ou seja, de acordo com seus nomes. Para isso, iremos definir na próxima célula uma variável: `y = frutas["fruit_label"]` e teremos os rótulos de cada uma das frutas onde tínhamos os dados, que as maçãs eram rótulo "1" tangerinas: rótulo "2", laranjas: rótulo "3" e limão: rótulo "4". No rótulo "y", agora, teremos essa informação. Podemos, mais uma vez, executar a apresentação do gráfico, onde, na célula, iremos ter: `plt.scatter`, que é o gráfico de dispersão, (X1, X2) e iremos acrescentar: `c=y`, o que vai garantir que as cores serão de acordo com os rótulos das frutas. E as três linhas seguintes serão: `plt.xlabel("comprimento")`, na próxima linha: `plt.ylabel("altura")` e na última linha: `plt.show()`.

Ao executar esta linha, teremos um gráfico em que as frutas terão cores diferentes, de acordo com a sua fruta. Dessa maneira, podemos construir gráficos sobre o conjunto de dados. Até aqui, você pode compreender, de maneira introdutória como fazer leituras e análises de um conjunto de dados com Python. Aprofunde seus

conhecimentos analisando diferentes tipos de conjuntos de dados. Para isso, você pode pesquisar em repositórios gratuitos na internet para aplicar o que você aprendeu em cenários diferentes. Não esqueça de resolver os exercícios propostos e revisar todo o conteúdo abordado. Bons estudos e até a próxima!