

Introdução ao pré-processamento de dados com Python

Olá! Nesta aula, iremos trabalhar com pré-processamento de dados.

Nem todos os dados com os quais iremos trabalhar virão perfeitos. E o que queremos dizer com "perfeitos"?

Alguns dos dados tendem a fugir de padrões ou, até mesmo, a ter dados ausentes em seu conjunto.

Imagine uma pulseira, uma smartband que é capaz de efetuar a leitura dos batimentos cardíacos um monitor cardíaco.

Essa smartband está sempre coletando os dados de seu usuário.

Imagine o seguinte: em algum momento, a sua bateria pode acabar e ela não ter autonomia para continuar efetuando a leitura desses batimentos e, por algum motivo, você precisa desse conjunto de dados para efetuar alguma técnica de aprendizado de máquina.

E, geralmente, os algoritmos de aprendizado de máquina não possuem robustez suficiente para serem capazes de trabalhar com dados ausentes. Nesse caso, precisamos pré-processar os dados a fim de que esses dados não sejam ou se tornem inviáveis.

Logo, se faz necessário que possamos pré-processá-los e, de alguma maneira, tratar esses dados.

Outras situações envolvem, também o caso de alguns dados que possam fugir de algum padrão.

Imagine uma pessoa que tem uma vida normal faz suas compras e efetua pagamentos.

Do ponto de vista de um banco, ela terá um perfil de compras normal.

Vamos supor que existe um algoritmo de aprendizado de máquina de Machine Learning, que gostaria de descobrir quando essa pessoa vai ser vítima de uma fraude, ou seja, dada uma transação aquela transação não faça parte do perfil dessa pessoa. Então, imagine o seguinte: existem algumas compras que podem fugir do padrão da pessoa como a compra de um imóvel, por exemplo.

Um imóvel, geralmente, é uma das compras ou uma das transações, mais altas que podemos fazer.

Está bem além dos valores das compras normais.

Logo, precisamos, de alguma maneira, tratar os dados para que essa compra anormal não entre no nosso sistema uma vez que o sistema é feito para detectar compras fora do padrão.

E esta também é uma compra fora do padrão, porém, ela não é uma transação anômala.

Ela não é uma fraude. Logo, precisamos, de alguma maneira automatizada descobrir quais são essas compras para tentar evitá-las.

Ou seja, também devemos tratar os dados que estão fora de algum padrão.

Por isso, temos a importância desta aula que seria para pré-processar os dados a fim de que o modelo de aprendizado de máquina construído não seja enviesado por alguns elementos fora do padrão no nosso conjunto de dados.

Para esta aula, iremos prosseguir utilizando a biblioteca Pandas, para a leitura dos arquivos.

Então, iniciaremos a primeira célula do nosso Jupyter Notebook utilizando a linha, para importar o Pandas.

Então, teremos, na primeira célula: `"import pandas as pd"`., ou seja, um comando para importar uma biblioteca: `"import"` `"pandas"`, que é o nome da nossa biblioteca `"as"`, que seria um comando para dar um apelido para a nossa biblioteca e `"pd"`, que será a string que utilizaremos para chamar alguma função do Pandas e iremos executar esta célula.

A execução dessa célula não dá nenhum retorno uma vez que importar bibliotecas não deve ter retorno algum a não ser que seja um retorno de `"warning"`, um aviso no caso de essa biblioteca estar desatualizada, ou algo do tipo.

Mas, no nosso caso, não devemos ter nenhum tipo de warning nenhum aviso, nenhum retorno.

Então, iremos utilizar nesta aula um conjunto de dados parecido com o conjunto que utilizamos na aula de Introdução à análise de dados com Python que seria um conjunto de dados de frutas.

Só que esse conjunto de dados de frutas estará um pouquinho diferente do que estamos acostumados a trabalhar. Quem não conhece esse conjunto, não tem problema iremos abordá-lo no decorrer desta aula.

Iremos colocar uma linha para efetuar a leitura desse conjunto de dados.

Então, iremos utilizar a variável: `"data"`, para dados, em inglês `"= pd"`, que é para chamar nossa biblioteca Pandas `".read_table"` read, de ler e table, de tabela

"`read_table`" que seria a função para ler o nosso conjunto de dados e iremos passar como parâmetro a seguinte string: "`fruit`", de fruta "`_data`", de dados "`with`", de com "`_colors`", de cores "`_miss`", de faltantes.

Ou seja, um conjunto de dados de: frutas, com cores, porém, com alguns dados faltantes.

E utilizaremos o formato ".txt", que é o formato do arquivo que está sendo passado juntamente com esta aula.

Então, a nossa linha no total ficou: "`data = pd.read_table('fruit_data_with_colors_miss.txt')`"

Ao executar esta linha, não teremos resultado nenhum pois, esta função não tem um retorno, mas o nosso conjunto de dados deverá estar na variável "`data`".

Irei, agora, usar na próxima linha, na próxima célula a variável "`data`", apenas para apresentar os dados.

Notaremos que nosso conjunto de dados é bem parecido com o conjunto de dados original, de frutas com cores um conjunto que possui sete colunas: o rótulo da fruta, ou "`fruit_label`" o nome da fruta: "`fruit_name`" o subtipo da fruta: "`fruit_subtype`" a massa da fruta: "`mass`" comprimento, ou largura da fruta: "`width`" a altura da fruta: "`height`" e a cor da fruta: "`color_score`".

Então, temos sete colunas nesse conjunto de dados e temos 60 elementos nesse conjunto.

Utilizando a função "`shape`", "`data.shape`" podemos verificar a quantidade de elementos.

São 59 elementos, para ser mais preciso e sete colunas.

Neste conjunto de dados, temos alguns dados faltantes.

No caso, temos três dados faltantes neste conjunto que estão na linha de número 3 ou quarta linha, visto que as linhas começam a partir do zero a massa é faltante, temos um ponto de interrogação nesta linha e na coluna de massa.

Na coluna "`fruit_subtype`", ou subtipo de fruta na linha de número 7, ou oitava linha temos um ".", ou seja, a informação que deveria estar lá foi substituída por um ponto final.

E na linha seguinte, de número 8, ou nona linha na altura da fruta, também temos um "." ou seja, temos três dados faltantes neste conjunto.

No próximo vídeo, iremos abordar como podemos trabalhar com esses dados faltantes para que eles não sejam um problema em uma determinada análise ou na construção de um modelo de aprendizado de máquina com Machine Learning.

Até lá!