

Introdução às árvores de decisão

Olá! Nesta aula, iremos começar a estudar mais um modelo de aprendizado de máquina conhecido como árvores de decisão. O modelo Árvores de decisão é um dos mais interessantes devido à sua capacidade de interpretabilidade.

É um modelo que possui uma ideia bem intuitiva e é altamente interpretável por um especialista.

Nós podemos construir este modelo a partir de um conjunto de dados, porém, uma vez construído este modelo conseguimos entender qual é a sua motivação para retornar uma classe, ou um valor, no caso de uma regressão. Então, as árvores de decisão podem ser bastante utilizadas juntamente com um especialista, que pode avaliar se as decisões que a árvore está retornando são, de fato decisões que possuem algum embasamento real uma vez que a teoria e a prática podem divergir um pouco. As árvores de decisão são conhecidas por serem um conjunto de regras "se-então" bem parecidas com uma ideia da lógica, o que facilita essa noção de interpretabilidade da parte delas.

Essas árvores de decisão são construídas a partir de um conjunto de dados. Para um exemplo simples, que iremos utilizar para entendermos melhor essas árvores, será o conjunto de dados de peixes. Queremos classificar peixes, de acordo com suas características então, teremos três colunas no nosso conjunto de dados simples para entendermos um pouco as árvores de decisão, que serão: o brilho de um peixe, afinal, o brilho de um peixe caracterizará um pouco a sua espécie até mesmo a sua qualidade, o quão fresco ele está além do tamanho desse peixe. Então, duas colunas de atributos: "brilho" e "tamanho" e temos, também, uma coluna de "classificação", de rótulo que seria o tipo do peixe. No caso, temos dois tipos de peixe que queremos classificar aqui que seriam o salmão ou o sea bass, que pode ser traduzido como "badejo". Então, dados dois tipos de peixes em um conjunto de dados que os contém nós iremos estudar um pouquinho as árvores de decisão e entender como suas decisões são tomadas. Iremos exemplificar um pouco como a árvore de decisão é construída a partir de um conjunto de dados. Então, dado o conjunto de dados de peixes, onde temos o "brilho", "tamanho" e "classificação" de cada peixe ou o rótulo desse peixe se seria um salmão ou um badejo temos o desafio de construir

uma árvore. A árvore de decisão é um processo de criar regras "se-então". Utilizamos bastante a árvore binária na computação a árvore binária de busca, por exemplo, e o processo de criação da árvore de decisão é um pouco parecido, logo devemos ter um resultado similar ao das árvores, onde podemos interpretar cada nó desta árvore como uma regra. No caso do nosso conjunto de dados temos vários tamanhos de peixes e seus respectivos brilhos. E, no caso do nosso conjunto de exemplo, temos a árvore de decisão construída a partir desses dados.

Ela foi feita da seguinte maneira: os peixes cujo tamanho for maior do que 25 serão classificados como "Salmão". Ou seja, essa é a primeira regra. E os peixes que forem

menores que 25 com tamanho menor ou igual a 25 irão cair em outra regra de classificação que seria a análise do brilho. Caso o brilho seja maior que 0,9 o nosso peixe é classificado como "Salmão" e caso ele seja menor ou igual a 0,9 será "Sea bass". E, assim se encerra nossa árvore de decisão. Dessa maneira, tivemos três regras

do tipo "se-então": se o tamanho é maior que 25, então temos um "Salmão". Se é menor ou igual a 25, e tem brilho maior que 0,9 o peixe é um "Salmão". E se o tamanho é menor ou igual a 25, e o brilho é menor ou igual a 0,9, o peixe é um "Sea bass".

Então, essas regras "se-então" são bem familiares para a análise humana.

Nós conseguimos entender bem estas regras conseguimos perceber a sua fluidez e o que elas estão querendo dizer de uma maneira bem simples. Então, o processo de construir uma árvore de decisão passa por construir essas regras de "se-então" a partir do nosso conjunto de dados. Estamos utilizando um conjunto de dados simples para tentar fazer essa classificação e iremos estudar um pouquinho sobre como obter essa árvore a partir do conjunto de dados.

Primeiramente, tentaremos executar divisões dentro das colunas de dados, ou seja, iremos tentar escolher um valor qualquer de "Tamanho" e tentar efetuar uma divisão. Ou seja, suponhamos que nós temos os tamanhos dos dados os tamanhos dos peixes variando entre "15" e "45". Podemos escolher aleatoriamente qualquer valor desse intervalo e escolher como uma divisão. Os peixes maiores que 30, por

exemplo, e menores ou iguais a 30 em seus tamanhos. Então, essa divisão irá separar o nosso conjunto de dados: teremos os peixes que são maiores que esse valor e os peixes que são menores que esse valor. Utilizando essa divisão, esse processo podemos verificar quão bem foram divididas as classes dos peixes. Para isso, iremos utilizar o índice de impureza do resultado da divisão. Existem alguns índices que podem ser utilizados, por exemplo, o índice Gini e a entropia dos dados. No caso, nós iremos utilizar o índice Gini que é um índice bastante utilizado na literatura inclusive, é o índice padrão da nossa biblioteca Scikit-learn. O índice Gini funciona da seguinte maneira: ele é calculado por: 1 menos o somatório da divisão dos nossos dados ao quadrado para cada classe. Então, vamos escolher um exemplo. Se escolhermos, por exemplo, o nosso brilho maior que 0,7 ou menor ou igual a 0,7 teremos a divisão dos dados da seguinte maneira: teremos um sea bass de um dos lados, ou seja, menor ou igual a 0,7 e nenhum salmão do outro lado. Em relação aos que possuem brilho maior ou igual a 0,7 nós teremos três sea bass e cinco salmões. Então, para calcular o índice Gini desta técnica iremos efetuar o seguinte cálculo: O Gini do lado dos menores que 0,7 será calculado da seguinte maneira: 1 menos, e teremos a soma das impurezas. No caso, nós temos um sea bass de um lado, e nenhum salmão. Então, esta divisão foi perfeita, pois não tivemos nenhuma mistura das duas classes abaixo de 0,7 de brilho. Então, como temos só um peixe deste lado da divisão iremos fazer a divisão de um sea bass sobre 1 que é o total elevado ao quadrado mais 0 salmões sobre 1 peixe, no total estamos tentando pegar o total de peixes vendo quais estão de cada lado, de cada classe e elevaremos ao quadrado, também, o lado dos salmões que é 0 sobre 1, que é igual a 0, elevado ao quadrado. De um lado, temos: 1 menos 1 sobre 1 um sea bass, de um peixe que ficou do lado menor que 0,7 ao quadrado, então temos: 1 menos 1 mais zero salmões sobre um peixe, 1, que é a quantidade de peixes igual a 0, elevado ao quadrado, que também é 0, então teremos: 1 menos 1 mais 0, ou seja, o Gini deste lado será igual a 0. Já do outro lado, temos uma mistura: os peixes cujo brilho é maior que 0,7 teremos três sea bass e cinco salmões. Então, isso irá resultar em um Gini igual a: 1 menos 3 sea bass sobre 8 peixes, no total que ficaram deste lado, elevado ao quadrado mais 5 salmões sobre 8 peixes elevado ao quadrado. O resultado dessas contas que nós temos é que do lado

dos menores ou iguais a 0,7 nosso Gini foi igual a 0. Porém, do lado dos valores maiores que 0,7, teremos: 1 menos 0,375 que é 3 sobre 8, elevado ao quadrado + 0,625 que é 5 sobre 8, elevado ao quadrado igual a 0,47. Então, no total, iremos ter um Gini pegando esses mesmos valores e aplicando, novamente, na fórmula do Gini teremos um Gini igual a 0,42. Quanto mais próximo de 0 o nosso Gini for, melhor, ou seja, quanto menor o valor da impureza, melhor. 0,42 é um valor bem alto uma vez que nossos valores têm, no máximo, 0,5. Então, essa divisão do brilho menor que 0,7 ou maior que 0,7 não é uma boa divisão. Aplicando outra divisão escolhendo o tamanho maior que 25

teremos uma divisão que é bem melhor, pois os peixes que são menores ou iguais a 0,25 serão quatro sea bass e um salmão. Se formos calcular o Gini deste resultado teremos 0,32 de impureza. E os peixes cujo tamanho é maior que 25 são zero sea bass e quatro salmões. Como temos quatro sea bass, de um lado, e quatro salmões a divisão foi perfeita, e temos um total de 0 neste Gini. Então, o cálculo total do nosso Gini reaplicando esses valores na fórmula de Gini teremos o valor 0,8 de impureza o que é bem melhor que a impureza anterior. Desta maneira, conseguimos perceber que a divisão considerando o tamanho de 25 menores ou iguais a 25, e maiores que 25 deu uma impureza bem menor que o resultado anterior. E o processo será exatamente esse. Iremos aplicar esta técnica várias vezes de modo que possamos verificar qual é a melhor divisão. Então, para cada coluna, serão percorridos todos os valores no intervalo dos dados e serão efetuados os cálculos do Gini. E isso será feito para todas as colunas. No momento em que encontrarmos a divisão na coluna que retornar o menor valor de Gini esta será a escolhida para ser a primeira divisão dos dados. E, assim, iremos repetir o processo para cada uma das classes que estiverem desbalanceadas. Por exemplo: nesta divisão de tamanho maior que 25 ou tamanho menor ou igual a 25 temos que o nosso salmão ficou bem dividido para os valores de tamanho maior que 25 tivemos nenhum sea bass e quatro salmões então, essa divisão já foi perfeita, não precisamos continuar dividindo. E, do outro lado, os peixes com tamanho menor ou igual a 25 nós temos quatro sea bass e um salmão, ou seja, vale a pena continuar efetuando divisões criando regras para os peixes que estão deste lado para os peixes que tem tamanho menor ou igual a 25. Então, o processo

é repetido dentro do intervalo de valores das colunas desses peixes, não iremos utilizar a divisão no intervalo de valores que tínhamos antes. Agora, é um novo conjunto de dados, apenas com esses peixes os quais iremos percorrer seus valores e verificar qual seria a melhor divisão. Dessa maneira, temos a nossa técnica de construção de árvores e a árvore vai sendo construída dessa maneira até que nenhuma impureza permaneça no nosso conjunto. Assim, podemos construir nossa árvore de decisão e utilizá-la para a classificação dos nossos dados. No próximo vídeo, iremos aprender a implementar essa técnica da árvore de decisão.

Até lá!